

Metodologia — Modello di siting e validazione, provincia di Milano

Progetto EV Charge Desert | Come si stima quante colonnine servono e dove installarle su scala provinciale, e come si verifica che il modello funzioni davvero, confrontandolo con colonnine reali già esistenti

1. Obiettivo

Le fasi precedenti del progetto (scraping traffico e POI, siting) sono state sviluppate e verificate su 50 sezioni di censimento scelte come le più critiche dell'area di Milano. Questa fase estende lo stesso modello a scala provinciale, con due obiettivi distinti: (1) applicarlo davvero alle sezioni che ne hanno bisogno — quante colonnine servono e dove installarle — e (2) verificarne l'affidabilità con una controprova quantitativa, non solo un giudizio qualitativo sulle mappe.

L'idea della controprova: alcune sezioni della provincia sono oggi servite da colonnine reali già installate. Se si toglie (solo nella simulazione) quella colonnina e si fa finta che la sezione sia ancora scoperta, il modello dovrebbe proporre un punto di siting vicino a dove quella colonnina si trova davvero — altrimenti il criterio usato per scegliere i punti non cattura un segnale reale, solo un'ipotesi plausibile sulla carta.

2. Perché non l'intera provincia

La provincia di Milano ha 13.557 sezioni di censimento. Il modello, però, serve solo su due gruppi mirati, non su tutte:

- **818 sezioni critiche** — gap_score sopra la soglia critica nazionale (metodo del gomito, soglia = 0,4287): qui il modello va applicato per davvero.
- **150 sezioni di controprova** — per la verifica quantitativa (§6).

Il campione di controprova richiede una spiegazione più lunga. L'idea iniziale era semplice: prendere le sezioni oggi servite (con almeno una colonnina entro 500m) che “tornerebbero critiche” se quella colonnina sparisse, e usarle come banco di prova. Per calcolarlo davvero serve sapere DOVE sono le colonnine reali — informazione che non era ancora stata usata nella pipeline: è stata trovata nel dataset *pun_colonnine_pulito.csv* (72.648 colonnine pubbliche reali con coordinate esatte), già raccolto per la pipeline principale del progetto ma non ancora incrociato con il modello di siting.

Ricalcolando con le coordinate reali (non con un campo del dataset nazionale che risultava vuoto per tutte le sezioni servite, si veda §7 per il dettaglio), è emerso un fatto inatteso: il numero di sezioni che “tornerebbero critiche” rimuovendo le loro colonnine resta alto (tra 4.360 e 5.391) a qualunque soglia minima di colonnine attuali si usi per filtrare. Non è quindi un effetto di casi limite (sezioni con una sola colonnina isolata): è strutturale al modo in cui il GAP score tratta l'offerta di colonnine — il salto da “servita” a “non servita” è un salto di percentile enorme, non uno scarto morbido. Servita comunque scegliere un campione deliberato, non un filtro “naturale”: **150 sezioni**, campionate in modo che nessun singolo comune domini il campione (124 comuni distinti rappresentati, su un pool di partenza di oltre 5.000 sezioni concentrato per metà a Milano città).

Totale sezioni target: **968** (818 + 150) — molto meno delle 13.557 della provincia, ma sufficienti a coprire entrambi gli obiettivi della fase.

3. Raccolta dati di traffico

Stessa pipeline delle fasi precedenti (TomTom Traffic Flow Vector Tile, zoom 15, congestione = 1 – velocità attuale/velocità a flusso libero, soglia di robustezza ≥ 5 letture per fidarsi di un segmento), scalata

alle 968 sezioni target: **803 tile** necessari (contro i 2.404 che servirebbero per l'intera provincia, e i 63 delle 50 sezioni originali — il conteggio scala con l'area coperta, non con il numero di sezioni).

3.1 Cadenza adattiva, non fissa

Una cadenza fissa a 5 minuti per l'intera raccolta costerebbe più del doppio della quota mensile disponibile (200.000 chiamate). La soluzione: **5 minuti nelle due fasce di punta** (7-10 e 17-20, ora locale italiana — dove il pattern da catturare è concentrato) e **15 minuti nel resto della finestra diurna**. Le ore notturne (22-7) sono escluse deliberatamente, non solo per risparmiare quota: la metrica usata ovunque nel progetto è la congestione MASSIMA per segmento, e di notte la circolazione è scorrevole quasi ovunque — quelle letture non risulterebbero quasi mai il massimo di un segmento, il taglio non peggiora la qualità del dato.

Perché infittire il fuori-punta invece di lasciare un margine ampio: più letture indipendenti durante la giornata aumentano la robustezza (soglia ≥ 5 letture) e permettono di cogliere eventuali picchi di congestione anche fuori dagli orari classici di punta. Risultato: **173.448 chiamate su 48 ore, 86,7% della quota mensile**, con un margine del 13% lasciato apposta per eventuali richieste fallite da ripetere.

3.2 Finestra di campagna: si avvia e si ferma da sola

La raccolta è programmata per iniziare **lunedì alle 00:00** (ora italiana) e coprire esattamente 48 ore (lunedì e martedì) — un giorno feriale “tipico”, non un giorno scelto a caso che potrebbe cadere di weekend o a ridosso di una festività. La finestra è scritta esplicitamente nello script: fuori da quell'intervallo, ogni tentativo di raccolta esce subito senza fare alcuna chiamata. Conseguenza pratica: il trigger esterno che innesca la raccolta può restare attivo H24 anche con giorni di anticipo (nessun costo prima che inizi la finestra) e non serve disattivarlo alla fine — la campagna si interrompe da sola, evitando di sfiorare la quota mensile per dimenticanza.

3.3 Formato di salvataggio

I dati vengono salvati in un file compresso per giorno, non in un unico file che cresce all'infinito: alla scala di questa raccolta un file unico rischierebbe di diventare troppo grande per essere gestito comodamente col passare dei giorni.

4. Raccolta dati sui punti di interesse (POI)

Stessa metodologia delle fasi precedenti, sulle 968 sezioni target invece delle 50 originali. Il traffico dice dove passano le auto, non dove possono fermarsi: i POI servono a individuare i luoghi dove un'auto sosta per un tempo comparabile a una sessione di ricarica.

Le categorie sono scelte con tre criteri concreti (tempo di sosta comparabile a una ricarica, area di sosta associata, visite ricorrenti), raggruppate in tre livelli di confidenza:

Livello	Categorie	Perché
1 — parcheggio quasi certo	distributore, supermercato, centro commerciale	Area dedicata praticamente garantita, precedente reale di installazione colonnine.
2 — parcheggio dedicato certo	parcheggio, ufficio/azienda, ospedale	Area di sosta dedicata certa, spesso con permanenza lunga.
3 — parcheggio plausibile	palestra/centro sportivo, ristorazione, cinema	Sosta di durata utile, ma l'area di parcheggio non è sempre garantita.

Un POI appartiene a una sezione se cade dentro il suo confine ESATTO, non entro un raggio arbitrario dal centroide (le sezioni periferiche superano i 600×700 metri: un raggio fisso coprirebbe solo il centro del

poligono). Per la query grezza ai server OpenStreetMap/Overpass si usa invece un rettangolo di ricerca (bounding box) più largo del confine, non il contorno esatto della sezione: un test diretto ha mostrato che il filtro poligonale esatto, su un poligono bufferizzato con oltre 100 vertici, porta il tempo di risposta del server da 1-2 secondi a 30 secondi e oltre (spesso in timeout) — un costo enorme senza benefici, perché l'assegnazione precisa avviene comunque nello step successivo, sul confine vero.

Per la stessa ragione di dipendenza dal PC (§3.2), lo scraping POI — che alla scala di 968 sezioni richiede più tempo dei pochi minuti sufficienti per le 50 originali — gira anch'esso su un'esecuzione automatica esterna invece che sul computer dell'utente, così da non fermarsi se il PC viene spento.

5. Quante colonnine servono

Stessa simulazione delle fasi precedenti (GAP score = rango percentile nazionale della domanda meno rango percentile nazionale dell'offerta; installare nuove colonnine entro 500m sposta solo il rango di offerta, la domanda resta invariata), applicata a tutte le 818 sezioni critiche invece che a una sola sezione scelta come esempio. Per ciascuna sezione si simula l'aggiunta progressiva di colonnine (0, 1, 2, ...) fino a individuare il primo scenario che fa scendere il GAP score sotto la soglia critica nazionale.

Questo calcolo non richiede i dati di traffico o POI (usa solo il dataset nazionale del GAP score) ed è già stato eseguito su dati reali:

Colonnine necessarie	N. sezioni
1	400
2	344
3	74

Nessuna delle 818 sezioni critiche richiede più di 3 colonnine per scendere sotto soglia.

6. Dove installarle

Stessa metodologia delle fasi precedenti, applicata alle 968 sezioni target. Il criterio è un imbuto in due fasi, non un punteggio unico che media traffico e POI insieme (il rischio di mediare: il punto risultante può cadere in un luogo senza senso fisico, né una strada né un'area di sosta).

- **Fase 1 — quali punti sono installabili.** Solo i POI di livello 1-3 sono candidati: un punto deve avere un'area di sosta plausibile.
- **Fase 2 — quali candidati hanno domanda reale confermata.** Il traffico vicino a ciascun candidato fa da classifica, con un peso che decresce linearmente con la distanza (zero oltre 300m) invece di un cutoff netto — un cutoff netto è fragile: un candidato molto vicino alla domanda reale può sparire dalla classifica solo per un arrotondamento sulla soglia.

Una selezione finale scarta i candidati troppo vicini a uno già scelto nella stessa sezione (diversificazione spaziale, entro 100m), per evitare di raccomandare due punti che sono di fatto lo stesso incrocio.

Punto importante per la validazione (§7): tra le categorie di POI usate come candidati non compare mai “colonnina di ricarica”. Il modello è quindi strutturalmente cieco alle colonnine esistenti — non serve nessuna maschera aggiuntiva per la controprova.

7. Validazione a controprova

È la parte nuova di questa fase rispetto a quelle precedenti: una verifica quantitativa, non solo un giudizio visivo sulle mappe.

7.1 Come si costruisce il campione

Punto di partenza: le sezioni oggi servite da almeno una colonnina reale entro 500m. Per ciascuna si simula la rimozione delle colonnine locali e si ricalcola il GAP score usando come nuova “distanza dalla colonnina più vicina” quella verso la colonnina reale più vicina rimasta fuori dal raggio di 500m (calcolata sulle coordinate esatte di *pun_colonnine_pulito.csv*, non su un campo del dataset nazionale che per queste sezioni risultava sistematicamente vuoto — la distanza dalla colonnina più vicina viene normalmente calcolata solo per le sezioni già scoperte, non serviva finora per quelle servite). Le sezioni il cui GAP score simulato risale sopra la soglia critica formano il pool eleggibile; da questo pool si campionano le 150 sezioni di controprova, distribuite su 124 comuni diversi (§2).

7.2 Come si valuta il modello

Per ciascuna delle 150 sezioni di controprova, si applica il modello di siting (§6) esattamente come per una sezione critica qualunque — con la sola differenza che qui esiste già una risposta nota (dove sta davvero la colonnina rimossa). Si misura la distanza in metri tra il punto raccomandato dal modello (il primo in classifica) e la colonnina reale più vicina, aggregata su tutte le 150 sezioni: mediana, e percentuale di casi entro 100m, 250m e 500m. Si registra anche la distanza del candidato migliore tra i primi 3 raccomandati, per distinguere “il primo in classifica è quello giusto” da “il modello ci arriva vicino, ma non lo mette al primo posto”.

Perché è una prova valida e non circolare: il modello non riceve mai in input la posizione delle colonnine reali (§6) — se nonostante questo i punti raccomandati cadono vicino a dove le colonnine sono state installate per davvero, è un'evidenza indipendente che il criterio di siting cattura un segnale reale legato alla domanda di ricarica, non solo un'ipotesi plausibile sulla carta.

I risultati numerici di questa validazione non sono ancora disponibili in questo documento: richiedono che la raccolta di traffico (§3, parte da lunedì) e quella dei POI (§4) siano complete. La metodologia è comunque già definita, implementata e verificata con dati di prova prima dell'avvio della raccolta reale.

8. Limiti e uso corretto

- Il campione di controprova (150 sezioni) è appunto un campione, non l'intero pool eleggibile (che supera le 5.000 sezioni): i risultati vanno letti come un'indicazione affidabile ma non esaustiva della bontà del modello.
- Il modello non vede mai le colonnine esistenti, ma un confondimento resta possibile: un'area già scelta in passato per installare una colonnina spesso ha anche più POI in generale (più parcheggi, più negozi) — una correlazione di sfondo che nessun disegno sperimentale di questo tipo può eliminare del tutto.
- I POI vengono da OpenStreetMap, una fonte volontaria: la copertura è tipicamente meno completa fuori dai grandi centri urbani (verificato in una fase precedente: un centro fitness locale realmente esistente, assente dalla mappa).
- Il calcolo di “quante colonnine servono” (§5) modifica solo la componente di offerta della sezione simulata, lasciando invariata la domanda: misura un effetto sul rango percentile nazionale, non una stima diretta della domanda fisica di ricarica soddisfatta.
- Il siting (§6) raccomanda i punti migliori TRA i candidati disponibili in una sezione, non garantisce che ogni sezione ne abbia: dipende dalla presenza di POI idonei e di traffico robusto abbastanza vicino.